LAPORAN PRAKTIKUM 3

CLASSIFICATION DENGAN ENSEMBLE METHOD & CLASS IMBALANCE

1. Pendahuluan

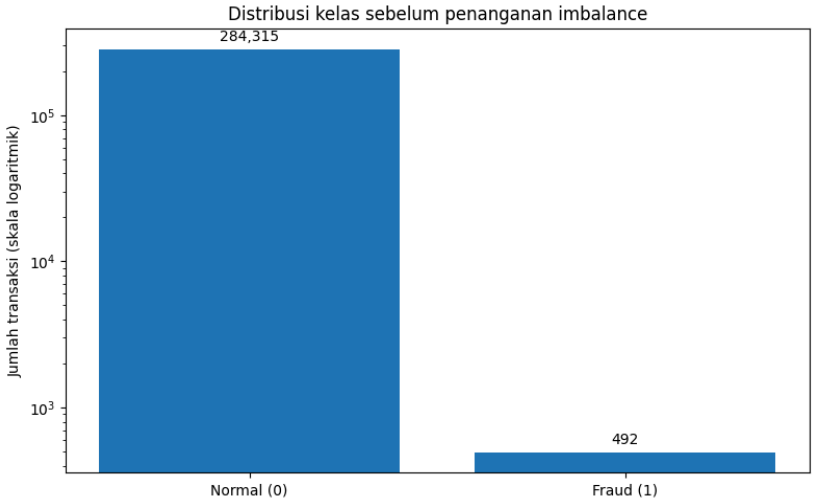
Deteksi penipuan kartu kredit (*credit card fraud detection*) merupakan masalah klasifikasi yang memiliki distribusi kelas sangat tidak seimbang. Transaksi normal jauh lebih banyak daripada transaksi *fraud*, sehingga *accuracy* yang tinggi belum tentu menunjukkan bahwa model mampu mengenali transaksi fraud dengan baik. Praktikum ini membangun model *ensemble Random Forest* dan membandingkan performanya sebelum dan sesudah penanganan *class imbalance* menggunakan *Synthetic Minority Over-sampling Technique* (SMOTE).

Tujuan eksperimen adalah mengidentifikasi ketidakseimbangan kelas, menerapkan *resampling* hanya pada data latih, serta mengevaluasi model memakai precision, recall, F1-score, AUC-ROC, dan confusion matrix. Evaluasi pada data uji tetap menggunakan distribusi kelas asli agar hasil lebih merepresentasikan kondisi data yang tidak seimbang.

2. Dataset dan Distribusi Kelas

Dataset yang digunakan adalah creditcard.csv dengan 284.807 baris dan 31 kolom. Terdapat 30 fitur masukan, termasuk Time, V1–V28, dan Amount, serta satu kolom target Class. Label Class = 0 menyatakan transaksi normal, sedangkan Class = 1 menyatakan transaksi *fraud*. Pemeriksaan struktur data menunjukkan seluruh kolom memiliki 284.807 nilai *non-null*, sehingga tidak ditemukan *missing value* pada pemeriksaan awal.

Kelas	Jumlah transaksi	Persentase
Normal (Class = 0)	284.315	99,8273%
Fraud (Class = 1)	492	0,1727%
Total	284.807	100,0000%



Gambar 1. Distribusi kelas sebelum penanganan imbalance (sumbu jumlah menggunakan skala logaritmik).

Jumlah transaksi normal sekitar 578 kali transaksi *fraud*. Karena *fraud* hanya 0,1727%, *model* yang selalu memprediksi normal dapat mencapai *accuracy* sekitar 99,83% tanpa mendeteksi *fraud*. Pemeriksaan awal juga mencatat 1.081 baris duplikat yang tidak ditangani lebih lanjut.

3. Metode dan Praproses Data

3.1. Pembagian data

Kolom Class dipisahkan sebagai target (y), sedangkan 30 kolom lainnya digunakan sebagai fitur (X). Dataset kemudian dibagi dengan train_test_split menggunakan test_size = 0,20, stratify = y, dan random_state = 42. Stratifikasi mempertahankan proporsi kelas pada data latih dan data uji.

Subset	Normal (0)	Fraud (1)	Total
Data latih	227.451	394	227.845
Data uji	56.864	98	56.962

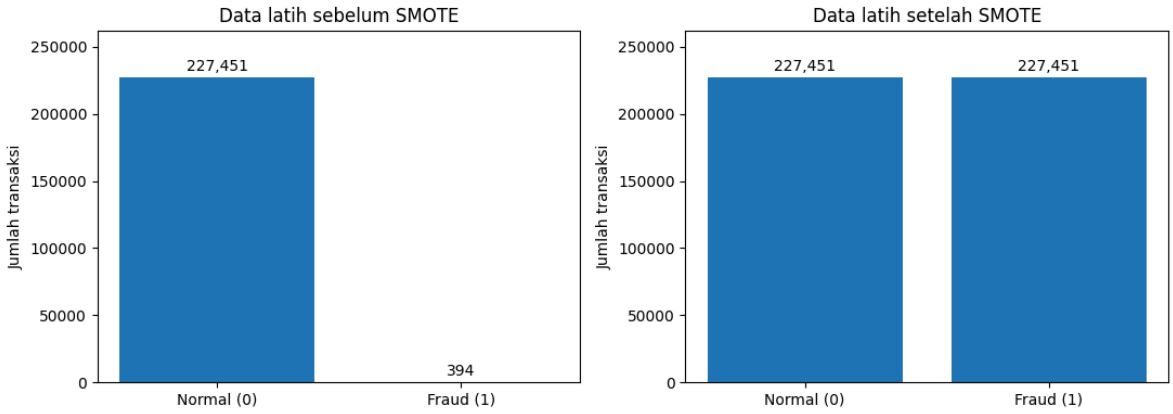
Data uji tidak di-*resampling* dan dipertahankan dalam distribusi aslinya. Dengan demikian, kedua model diuji pada 56.962 transaksi yang sama, termasuk 98 transaksi fraud.

3.2. Model baseline Random Forest

Model pertama adalah RandomForestClassifier dengan n_estimators = 100, random_state = 42, dan n_jobs = 2. Model dilatih menggunakan data latih asli tanpa *resampling*. Model ini menjadi *baseline* untuk mengetahui performa ketika ketidakseimbangan kelas belum ditangani secara eksplisit.

3.3. Penanganan class imbalance dengan SMOTE

SMOTE diterapkan menggunakan random_state = 42 pada data latih saja. Teknik ini membentuk sampel sintetis untuk kelas minoritas berdasarkan tetangga terdekat sehingga jumlah sampel kelas fraud menjadi sama dengan kelas normal. Jumlah data latih berubah dari 227.845 menjadi 454.902 baris, sedangkan data uji tetap 56.962 baris.



Gambar 2. Perbandingan distribusi kelas pada data latih sebelum dan sesudah SMOTE.

Setelah SMOTE, data latih terdiri atas 227.451 transaksi normal dan 227.451 transaksi *fraud*. Model Random Forest kedua dilatih dengan konfigurasi yang sama seperti *baseline*, tetapi menggunakan hasil *resampling*. Penggunaan konfigurasi yang sama membantu memusatkan perbandingan pada perubahan akibat penerapan SMOTE.

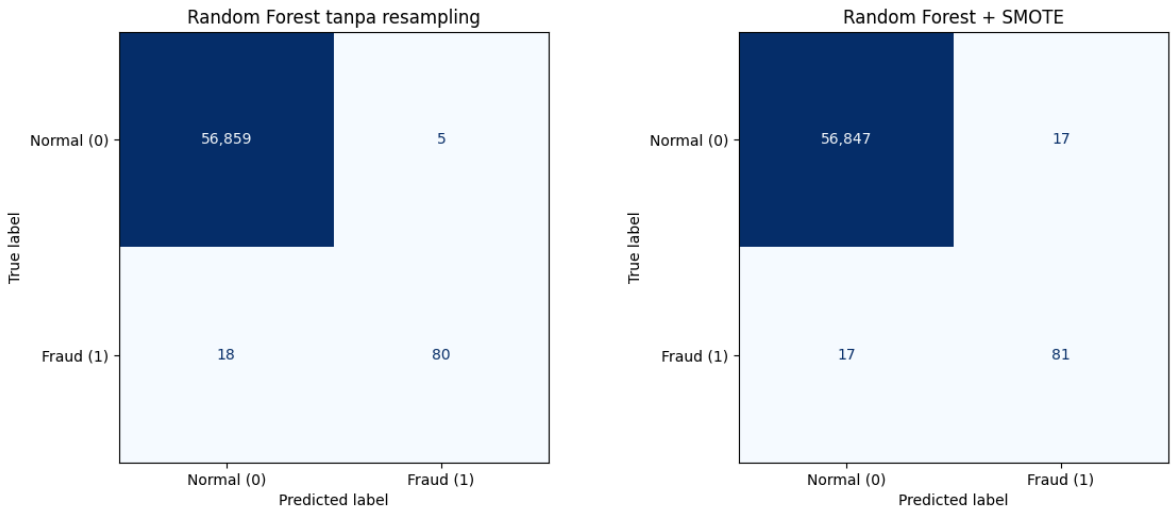
4. Hasil Evaluasi Model

Kedua model dievaluasi pada data uji yang sama menggunakan accuracy, precision, recall, F1-score, dan AUC-ROC. Nilai yang ditampilkan merupakan keluaran evaluasi pada notebook dan dibulatkan menjadi empat angka desimal.

Model	Accuracy	Precision	Recall	F1-score	AUC-ROC
Random Forest tanpa *resampling*	0,9996	0,9412	0,8163	0,8743	0,9630
Random Forest + SMOTE	0,9994	0,8265	0,8265	0,8265	0,9644

Tabel 2. Perbandingan metrik kedua model pada data uji.

4.1. Confusion matrix

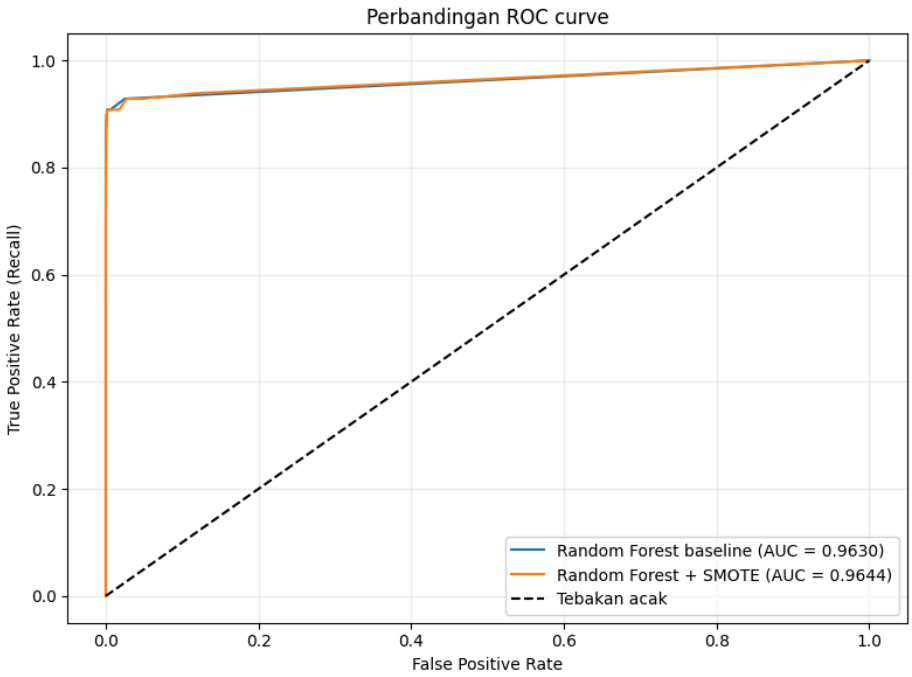


Gambar 3. Confusion matrix model Random Forest baseline dan Random Forest + SMOTE.

Pada model baseline, 80 dari 98 transaksi *fraud* terdeteksi benar (*true positive*), sedangkan 18 transaksi *fraud* terlewat (false negative). Model ini menghasilkan 5 *false positive*, yaitu transaksi normal yang salah ditandai sebagai *fraud*. Setelah SMOTE, 81 transaksi *fraud* terdeteksi benar dan 17 terlewat, tetapi jumlah *false positive* meningkat menjadi 17.

Dengan demikian, SMOTE membantu menangkap satu transaksi *fraud* tambahan pada data uji, tetapi juga menambah 12 *false positive*. *Trade-off* ini menjelaskan mengapa recall meningkat sementara precision dan F1-score menurun. Pilihan model akhir perlu mempertimbangkan biaya transaksi fraud yang terlewat dan biaya pemeriksaan transaksi normal yang keliru ditandai.

4.2. ROC curve dan AUC-ROC



Gambar 4. ROC curve untuk membandingkan kemampuan pemisahan kelas kedua model.

AUC-ROC meningkat tipis dari 0,9630 menjadi 0,9644 (+0,0014). Kurva kedua model berdekatan, menandakan kemampuan pemisahan kelas yang serupa dengan sedikit keunggulan pada model SMOTE.

5. Pembahasan

Setelah SMOTE, recall naik dari 0,8163 menjadi 0,8265 dan AUC-ROC dari 0,9630 menjadi 0,9644. Namun, precision turun dari 0,9412 menjadi 0,8265 dan F1-score dari 0,8743 menjadi 0,8265. *Baseline* lebih presisi, sedangkan SMOTE menangkap satu *fraud* tambahan dengan konsekuensi *false positive* yang lebih tinggi.

Accuracy saja tidak cukup: karena kelas normal mendominasi, model yang selalu memprediksi normal pun mencapai sekitar 99,83% accuracy tanpa mendeteksi *fraud*. Recall, precision, F1-score, dan AUC-ROC memberi gambaran lebih relevan tentang deteksi *fraud* dan risiko alarm keliru.

6. Keterbatasan Eksperimen

- Sebanyak 1.081 baris duplikat teridentifikasi tetapi tidak ditangani. Dampaknya perlu dianalisis sebelum memutuskan penghapusan.
- SMOTE tidak didahului standardisasi fitur. Karena berbasis jarak, skala Time dan Amount dapat memengaruhi sampel sintetis, eksperimen lanjutan sebaiknya menguji penanganan skala fitur.
- *Threshold* standar digunakan, optimasi *threshold* dan analisis biaya false positive/false negative belum dilakukan.

7. Kesimpulan

Dataset sangat tidak seimbang: 492 dari 284.807 transaksi (0,1727%) berlabel fraud. Random Forest *baseline* unggul pada precision (0,9412) dan F1-score (0,8743), SMOTE memiliki recall

(0,8265) dan AUC-ROC (0,9644) sedikit lebih tinggi. Pada data uji, SMOTE menemukan satu *fraud* tambahan, tetapi *false positive* naik dari 5 menjadi 17. SMOTE tidak unggul pada semua metrik, pemilihan model perlu menimbang fraud yang terlewat dan biaya alarm palsu.