

LAPORAN ANALISIS PRAKTIKUM 2: PRAPROSES DATA

5054251037 | Lioneil Diyoel Trystan Tikupadang

1. Pendahuluan

Praktikum ini bertujuan melakukan praproses pada dataset *House Prices - Advanced Regression Techniques* agar data lebih bersih dan siap digunakan untuk analisis atau tahap pemodelan berikutnya. Tahapan yang dilakukan mengikuti panduan praktikum, yaitu pemeriksaan awal dataset, penanganan missing value, deteksi dan penanganan outlier, standardisasi, one-hot encoding, reduksi atribut berdasarkan korelasi, serta PCA. Hasil akhir yang diekspor ke CSV berhenti sebelum PCA, sedangkan PCA dilakukan di notebook sebagai demonstrasi reduksi dimensi.

2. Dataset dan Pemeriksaan Awal

Dataset yang digunakan adalah file train.csv dengan 1.460 baris dan 81 kolom. Pemeriksaan awal dilakukan menggunakan head(), shape, dan info(). Dataset terdiri dari atribut numerik dan kategorikal, dengan Id sebagai identifier dan SalePrice sebagai target. Id dipertahankan agar setiap baris hasil preprocessing tetap dapat dilacak, tetapi tidak digunakan dalam standardisasi, korelasi, atau PCA.


Tahap	Hasil
Ukuran dataset awal	1.460 baris x 81 kolom
Identifier	Id
Target	SalePrice
Pemeriksaan missing value	Ditemukan pada beberapa atribut

3. Pembersihan Data - Missing Value

Pemeriksaan missing value dilakukan dengan menghitung jumlah dan persentase nilai yang hilang pada setiap atribut. Atribut dengan proporsi missing lebih dari 50% dihapus dan hasil pemeriksaan menunjukkan terdapat lima atribut yang memenuhi kondisi tersebut.

Atribut	Jumlah Missing	Persentase
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
MasVnrType	872	59,73%


Setelah penghapusan, ukuran dataset berubah dari 1.460 x 81 menjadi 1.460 x 76. Missing value yang masih tersisa ditangani berdasarkan tipe dan konteks atribut. Atribut numerik LotFrontage, GarageYrBlt, dan MasVnrArea diisi dengan median. Atribut kategorikal yang merepresentasikan fasilitas rumah seperti FireplaceQu, Garage*, dan Bsmt* diisi dengan "None" untuk menunjukkan tidak adanya fasilitas. Atribut kategorikal lain yang masih kosong, yaitu Electrical, diisi dengan modus. Setelah tahap ini, jumlah missing value yang tersisa adalah 0.



Gambar 1. Persentase nilai hilang per atribut. Garis putus-putus menunjukkan batas 50%.

4. Deteksi dan Penanganan Outlier


Deteksi outlier dilakukan menggunakan boxplot dan ringkasan IQR pada 36 atribut numerik. Id tidak diperiksa karena hanya identifier, sedangkan MSSubClass tidak diperlakukan sebagai numerik kontinu karena merupakan kode kelas bangunan. SalePrice tetap ditampilkan dan diperiksa secara visual, tetapi tidak dimodifikasi karena merupakan target.



Gambar 2. Contoh hasil pemeriksaan boxplot atribut numerik (1-9 dari 36 atribut yang diperiksa).

Berdasarkan pemeriksaan boxplot dan ringkasan IQR, penanganan difokuskan pada atribut ukuran rumah yang menunjukkan nilai ekstrem dan merupakan fitur numerik kontinu. Empat atribut yang dipilih adalah LotArea, GrLivArea, TotalBsmtSF, dan 1stFlrSF. Outlier ditangani dengan IQR capping agar seluruh baris tetap dipertahankan dan pengaruh nilai yang sangat ekstrem dibatasi.

Atribut	Jumlah Outlier	Persentase	Batas IQR
LotArea	69	4,73%	1.481,5 - 17.673,5
TotalBsmtSF	61	4,18%	42 - 2.052
GrLivArea	31	2,12%	158,625 - 2.747,625
1stFlrSF	20	1,37%	118,125 - 2.155,125



Gambar 3. Boxplot empat atribut setelah dilakukan IQR capping.

Sebagai catatan, SalePrice terdeteksi memiliki 61 nilai di luar batas IQR pada pemeriksaan awal, tetapi tidak di-capping dan tidak dihapus karena diperlakukan sebagai target. Penanganan outlier tidak dilakukan dengan menghapus baris data secara agresif.

5. Transformasi Data

5.1 Standardisasi

MSSubClass diubah menjadi tipe kategorikal sebelum standardisasi sehingga tidak diperlakukan sebagai variabel kontinu. Id tidak ikut scaling karena hanya identifier, dan SalePrice dipertahankan dalam skala aslinya sebagai target. Sebanyak 35 fitur numerik lainnya distandarisasi menggunakan StandardScaler (z-score). Hasil pemeriksaan menunjukkan mean fitur mendekati 0 dan standar deviasi mendekati 1.


Komponen	Perlakuan
Fitur numerik	35 fitur distandarisasi dengan StandardScaler
Id	Tidak distandarisasi
SalePrice	Tidak distandarisasi
MSSubClass	Dipindahkan ke kategorikal

5.2 One-Hot Encoding

Setelah MSSubClass diperlakukan sebagai kategorikal, terdapat 39 atribut kategorikal. One-hot encoding dilakukan menggunakan drop_first=True sehingga satu kategori referensi dari setiap atribut tidak dibuat sebagai kolom tambahan. Hasil dummy dibuat bertipe integer sehingga berisi nilai 0 dan 1. Ukuran data berubah dari 1.460 x 76 menjadi 1.460 x 258.

6. Reduksi Dimensi Berdasarkan Korelasi

Analisis korelasi digunakan pada fitur numerik, dengan Id dan SalePrice dikeluarkan dari kandidat atribut yang dapat dibuang. Pasangan dengan nilai korelasi absolut lebih dari 0,8 dianggap sangat berkorelasi. Untuk setiap pasangan, atribut kedua yang ditemukan pada matriks korelasi dibuang secara konsisten.




Gambar 4. Matriks korelasi fitur numerik.

Atribut 1	Atribut 2	Korelasi	Atribut yang dibuang
TotalBsmtSF	1stFlrSF	0,807	1stFlrSF
GrLivArea	TotRmsAbvGrd	0,836	TotRmsAbvGrd
GarageCars	GarageArea	0,882	GarageArea

Setelah tiga atribut tersebut dihapus, ukuran dataset hasil preprocessing menjadi 1.460 baris dan 255 kolom. Reduksi ini dilakukan pada fitur numerik yang sangat berkorelasi tanpa menghapus SalePrice.

7. PCA (Principal Component Analysis)

PCA dilakukan setelah preprocessing dan correlation-based feature reduction. Id dan SalePrice tidak dimasukkan ke input PCA, sehingga terdapat 253 fitur yang menjadi input. Jumlah komponen ditentukan dari cumulative explained variance dengan target minimal 90%. Hasil notebook menunjukkan bahwa 47 komponen diperlukan untuk mencapai target tersebut. Transformasi PCA benar-benar dilakukan menggunakan `fit_transform()`, menghasilkan data berukuran 1.460 x 47.



Gambar 5. Cumulative explained variance PCA dengan batas 90%.

Tahap PCA	Ukuran
Input PCA	1.460 x 253
Jumlah komponen	47
Output PCA	1.460 x 47
Target	Minimal 90% variansi terjelaskan

Dataset hasil PCA digunakan hanya untuk demonstrasi reduksi dimensi di notebook. Hasil PCA tidak dimasukkan ke CSV final karena CSV dimaksudkan sebagai dataset hasil preprocessing sebelum PCA.

8. Ringkasan Dataset Akhir

Dataset final merupakan hasil cleaning, penanganan outlier, standardisasi, one-hot encoding, dan correlation-based feature reduction. Dataset ini tidak menggunakan hasil PCA sebagai CSV final.

Komponen	Hasil akhir
Jumlah baris	1.460
Jumlah kolom	255
Missing value	0

Komponen	Hasil akhir
Id	Tetap tersedia sebagai identifier
SalePrice	Tetap tersedia dalam nilai asli
MSSubClass	Sudah di-one-hot encode
Kolom dummy	Representasi numerik 0/1
Kolom PCA di CSV	Tidak ada

Dengan demikian, CSV final berisi data yang sudah melalui seluruh tahap preprocessing yang diwajibkan sebelum PCA. Seluruh 1.460 baris dipertahankan karena penanganan outlier menggunakan capping, bukan penghapusan baris.

9. Kesimpulan

Praproses pada dataset House Prices dilakukan secara bertahap sesuai panduan praktikum. Lima atribut dengan missing value lebih dari 50% dihapus, sedangkan missing value yang tersisa ditangani dengan median, "None", atau modus sesuai karakteristik atribut. Outlier diperiksa menggunakan boxplot dan IQR, kemudian empat atribut ukuran rumah diproses dengan IQR capping tanpa menghapus baris. Fitur numerik yang relevan distandarisasi, MSSubClass diperlakukan sebagai kategorikal dan di-one-hot encode bersama atribut kategorikal lainnya. Analisis korelasi mengurangi tiga atribut yang memiliki korelasi absolut di atas 0,8. PCA selanjutnya berhasil mereduksi 253 fitur menjadi 47 komponen untuk memenuhi target minimal 90% variansi terjelaskan, tetapi hasil PCA tidak dimasukkan ke CSV final. Dataset akhir berukuran 1.460 baris dan 255 kolom dengan 0 missing value.