

LAPORAN ANALISIS PRAKTIKUM 1:

SCRAPING DAN EKSPLORASI DATA (EDA)

5054251037 | Lioneil Diyoel Trystan Tikupadang

1. Deskripsi Dataset

Dataset yang digunakan berisi data item Palworld yang diperoleh melalui web scraping dari Paldex.gg. Pengambilan data dilakukan dengan Requests dan BeautifulSoup, sedangkan beberapa halaman diproses secara bersamaan menggunakan ThreadPoolExecutor agar proses scraping lebih efisien. Dataset raw kemudian disimpan dalam CSV sebelum dilakukan preprocessing. Dataset pada notebook terdiri dari 1.594 baris dan 7 kolom setelah preprocessing. Lima fitur utama yang dianalisis adalah price, weight, stackable, rarity, dan category, name digunakan sebagai identitas item dan url sebagai referensi sumber.

2. Preprocessing dan Tipe Atribut

Nilai price dan weight diubah menjadi numerik, sedangkan stackable, rarity, dan category dipertahankan sebagai atribut kategorikal. Berdasarkan karakteristik datanya, price dan weight termasuk numerik kontinu, stackable dan category termasuk nominal, sedangkan rarity termasuk ordinal karena memiliki tingkatan kelangkaan.

Fitur	Tipe atribut
price	Numerik kontinu
weight	Numerik kontinu
stackable	Nominal
rarity	Ordinal
category	Nominal

3. Statistik dan Kualitas Data

Hasil statistik menunjukkan perbedaan yang cukup besar antara mean dan median pada price. Rata-rata harga adalah 58.011,09 Gold, sedangkan median dan modus sama-sama 10.000 Gold. Nilai maksimum mencapai 6.508.680 Gold. Pada weight, rata-rata 2,82 dengan median dan modus 0, serta nilai maksimum 50. Kondisi ini menunjukkan bahwa kebanyakan item memiliki harga dan berat yang relatif rendah, sementara beberapa item memiliki nilai yang jauh lebih tinggi.


Atribut	Mean	Median	Modus	Std	Min	Max
price	58.011,09	10.000	10.000	349.463,18	1	6.508.680
weight	2,82	0	0	7,79	0	50

Missing value paling banyak terdapat pada price, yaitu 143 data (8,97%). Weight, stackable, dan rarity masing-masing memiliki 1 nilai kosong, sedangkan category tidak memiliki missing value. Nilai kosong pada price tidak langsung dihapus karena memang terdapat item yang tidak memiliki harga pada data sumber.

Deteksi outlier menggunakan metode IQR menghasilkan 187 kandidat outlier pada price dan 278 pada weight. Batas atas IQR masing-masing adalah 24.565 Gold untuk price dan 2,5 untuk weight. Nilai ekstrem tidak langsung dihapus karena masih dapat merupakan data yang valid untuk item tertentu.

4. Hasil Visualisasi dan Interpretasi

Visualisasi digunakan untuk melihat pola distribusi serta hubungan antaratribut. Karena rentang price sangat lebar, histogram price menggunakan skala logaritmik agar pola distribusinya lebih mudah dibaca. Sementara itu, distribusi category ditampilkan melalui 15 kategori dengan frekuensi tertinggi.



Gambar 1. Distribusi Price (skala logaritmik) | Gambar 2. 15 Kategori Item Teratas

Interpretasi

Histogram price memperlihatkan distribusi yang sangat menceng ke kanan. Sebagian besar item berada pada kisaran harga rendah, sedangkan sebagian kecil item mempunyai harga jauh lebih tinggi. Hal ini juga terlihat dari mean yang jauh di atas median. Pada category, Blueprint menjadi kategori paling dominan dengan 490 item, diikuti Pal gear (138 item), Boss rewards (102 item), dan Skill fruits (92 item).

Hubungan price dan weight memiliki korelasi Pearson sebesar 0,291. Nilai ini menunjukkan hubungan positif tetapi relatif lemah. Jadi, item yang lebih berat cenderung memiliki harga lebih tinggi, tetapi hubungan tersebut tidak cukup kuat untuk menjelaskan harga hanya dari weight.

5. Kesimpulan

Secara keseluruhan, hasil EDA menunjukkan bahwa dataset item Palworld memiliki variasi karakteristik yang cukup besar. Price dan weight cenderung memiliki right-skewness serta sejumlah nilai ekstrem. Dari atribut kategorikal, item yang stackable lebih banyak daripada yang tidak stackable, sedangkan Common merupakan rarity yang paling sering ditemukan. Analisis missing value dan outlier membantu melihat kualitas data sebelum digunakan lebih lanjut, sedangkan visualisasi memberikan gambaran bahwa category dan rarity dapat membedakan karakteristik item, walaupun hubungan price dengan weight sendiri tergolong lemah.