

LAPORAN ANALISIS PRAKTIKUM 1:

SCRAPING DAN EKSPLORASI DATA (EDA)

5054251037 | Lioneil Diyoel Trystan Tikupadang

1. Deskripsi Dataset

Dataset yang digunakan adalah data item Palworld dari Paldex.gg yang diperoleh melalui web scraping. Scraping menggunakan Requests dan BeautifulSoup, sedangkan beberapa halaman diproses bersamaan dengan ThreadPoolExecutor agar lebih efisien. Hasil scraping disimpan terlebih dahulu sebagai raw dataset dalam CSV.

Dari sitemap diperoleh 1.594 URL. Setelah data dibersihkan, satu baris yang berasal dari halaman indeks /items/ dihapus karena bukan item individual. Dataset akhir terdiri dari 1.593 observasi dan 7 atribut. Lima fitur utama yang dianalisis adalah price, weight, stackable, rarity, dan category. Atribut name digunakan sebagai identitas item, sedangkan url digunakan sebagai referensi sumber.

2. Cleaning, Preprocessing, dan Tipe Atribut

Cleaning dilakukan dengan menghapus baris yang bukan item dan duplikasi berdasarkan URL. Selanjutnya price dan weight dikonversi menjadi numerik, sedangkan stackable, rarity, dan category digunakan sebagai atribut kategorikal.

Atribut	Tipe	Keterangan
price	Numerik diskrit	Harga dalam Gold; nilainya berupa bilangan bulat
weight	Numerik kontinu	Berat dapat memiliki nilai desimal
stackable	Nominal	Status Yes/No tanpa urutan
rarity	Ordinal	Tingkatan kelangkaan memiliki urutan
category	Nominal	Kelompok/jenis item

3. Statistik dan Kualitas Data

Statistik deskriptif digunakan untuk melihat karakteristik atribut numerik.

Atribut	Mean	Median	Modus	Std	Min	Max
price	58.011,09	10.000	10.000	349.463,18	1	6.508.680
weight	2,82	0	0	7,79	0	50

3.1 Distribusi Atribut Kategorikal

Sebanyak 1.263 item berstatus stackable = Yes dan 330 item berstatus No. Pada rarity, COMMON paling banyak dengan 452 item, sedangkan UNCOMMON paling sedikit dengan 250 item. Untuk category, Blueprint merupakan kategori terbanyak dengan 490 item.

Rarity	Jumlah
COMMON	452
UNCOMMON	250
RARE	299
EPIC	337
LEGENDARY	255

3.2 Missing Value


Missing value hanya ditemukan pada price, yaitu 142 data atau 8,91%. Atribut weight, stackable, rarity, category, name, dan url tidak memiliki missing value pada dataset final. Data price yang kosong tidak diisi secara sembarang karena nilai sebenarnya tidak tersedia; pada analisis yang membutuhkan price, baris kosong diabaikan.

3.3 Outlier

Outlier dideteksi menggunakan metode Interquartile Range (IQR). Ditemukan 187 kandidat outlier pada price (11,74%) dan 278 kandidat outlier pada weight (17,45%). Batas atas IQR adalah 24.565 Gold untuk price dan 2,5 untuk weight. Nilai ekstrem dipertahankan karena masih dapat merupakan data yang valid.

4. Hasil Visualisasi dan Interpretasi


Visualisasi digunakan untuk melihat pola distribusi serta hubungan antaratribut. Karena rentang price sangat lebar, histogram price menggunakan skala logaritmik agar pola distribusinya lebih mudah dibaca. Sementara itu, distribusi category ditampilkan melalui 15 kategori dengan frekuensi tertinggi.



Gambar 1. Distribusi Price (skala logaritmik) | Gambar 2. Distribusi Item Weight


Distribusi Price: Sebagian besar item berada pada kisaran harga rendah hingga sekitar 10.000 Gold, sedangkan sebagian kecil item memiliki harga jauh lebih tinggi. Distribusi cenderung right-skewed. Skala logaritmik dipakai karena rentang harga sangat lebar, sehingga pola data lebih mudah terlihat.

Distribusi Item Weight: Sebagian besar item memiliki berat sekitar 0–1. Hanya sebagian kecil item yang memiliki berat lebih tinggi, sehingga distribusi weight juga cenderung miring ke kanan dan memiliki nilai ekstrem.



Gambar 3. Distribusi Stackable, Rarity, dan 15 Kategori Item Teratas

Interpretasi: Item yang dapat ditumpuk lebih banyak daripada yang tidak dapat ditumpuk. COMMON merupakan rarity yang paling sering ditemukan, sedangkan Blueprint merupakan category dengan frekuensi tertinggi. Hasil ini menunjukkan bahwa distribusi atribut kategorikal tidak merata pada seluruh kategori.



Gambar 4. Hubungan Price-Weight, Price-Rarity, Price-Category, dan Correlation Heatmap

Interpretasi: Scatter plot menunjukkan hubungan price dan weight yang tidak kuat. Boxplot memperlihatkan adanya nilai ekstrem pada beberapa rarity dan category. Heatmap menghasilkan korelasi Pearson sebesar 0,291, yang menunjukkan hubungan positif tetapi relatif lemah antara price dan weight.

5. Ringkasan Hasil EDA

Aspek	Hasil utama
Dataset	1.593 observasi, 7 atribut setelah cleaning dan preprocessing
price	Mean 58.011,09; median 10.000; maksimum 6.508.680 Gold
weight	Mean 2,82; median 0; maksimum 50
Stackable	1.263 Yes dan 330 No
Rarity	COMMON terbanyak (452), UNCOMMON paling sedikit (250)
Category	Blueprint terbanyak (490)
Missing value	price: 142 data (8,91%); atribut lain: 0
Outlier	price: 187 (11,74%); weight: 278 (17,45%)
Korelasi	price-weight: 0,291, positif tetapi relatif lemah

6. Kesimpulan

Berdasarkan hasil EDA, dataset item Palworld memiliki variasi yang cukup besar terutama pada price dan weight. Price memiliki rentang yang sangat luas dan distribusinya cenderung right-skewed, sedangkan weight sebagian besar berada pada nilai rendah.

Pada atribut kategorikal, item stackable lebih banyak daripada non-stackable, COMMON menjadi rarity yang paling sering ditemukan, dan Blueprint menjadi category yang paling dominan. Dari sisi kualitas data, missing value hanya ditemukan pada price dan sejumlah kandidat outlier ditemukan pada price dan weight.

Hasil korelasi menunjukkan hubungan positif tetapi relatif lemah antara price dan weight. Secara keseluruhan, proses scraping, cleaning, preprocessing, analisis statistik, dan visualisasi membantu memberikan gambaran mengenai struktur, distribusi, serta kualitas dataset sebelum digunakan untuk analisis lebih lanjut.